



(21)申请号 201510036233.1

审查员 孟腾

(22)申请日 2015.01.23

(65)同一申请的已公布的文献号

申请公布号 CN 104778834 A

(43)申请公布日 2015.07.15

(73)专利权人 哈尔滨工业大学

地址 150001 黑龙江省哈尔滨市南岗区西  
大直街92号

(72)发明人 安实 杨海强 崔建勋 王健

姚焱东 魏艳波

(74)专利代理机构 哈尔滨市松花江专利商标事

务所 23109

代理人 杨立超

(51)Int.Cl.

G08G 1/01(2006.01)

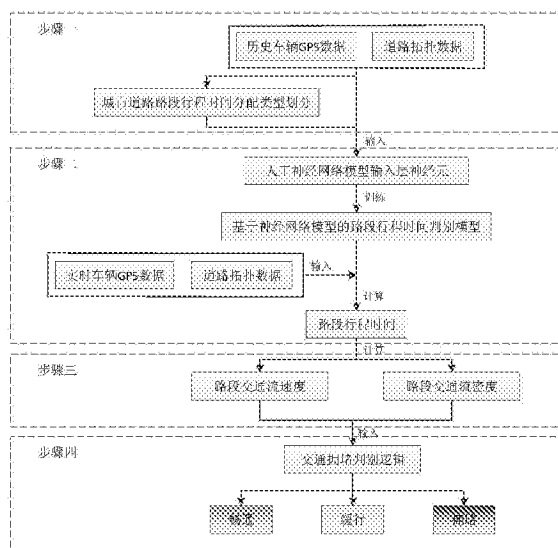
权利要求书3页 说明书7页 附图4页

(54)发明名称

一种基于车辆GPS数据的城市道路交通拥堵  
判别方法

(57)摘要

一种基于车辆GPS数据的城市道路交通拥堵判别方法,涉及一种城市道路交通拥堵判别方法。解决现有城市道路交通拥堵判别方法由于采用传统交通信息检测设备,使得依托于这些检测设备数据的交通拥堵判别方法的应用范围存在较大局限性的问题。基于人工神经网络模型构建城市道路路段行程时间预测模型;利用城市道路路段行程时间预测模型,根据车辆GPS获得的当前时刻的位置向量、路段编号向量、时间戳向量、速度向量,计算得到当前时刻的路段行程时间数据;基于路段行程时间数据进一步计算得出路段交通流速度和路段交通流密度;以路段交通流速度和密度数据为输入条件,判定道路交通拥堵状态。能供当前时刻的GPS数据便能迅速准确地判别交通拥堵状态。



1. 一种基于车辆GPS数据的城市道路交通拥堵判别方法,其特征在于,所述方法的实现过程为:

步骤一、以行驶于城市道路的车辆GPS数据为基础,结合城市道路拓扑结构信息,对不同类型的城市道路路段行程时间分配进行划分;得到目标路段的历史行程时间 $T_{s(i)}$ ;

所述目标路段的历史行程时间的到得方式为:

由于车辆GPS数据计算出的行程时间是车辆自一个路段的某一位置行驶到另一路段的某一位置得到的;将这一过程分为三种类型,并分别给出计算行程时间的方法:

第一种类型为所调查路段上存在至少两个车辆GPS定位点,在这种情况下,所调查路段的行程时间由此路段上首尾两GPS定位点之间的时间差值、上游交叉口到首个GPS定位点的行驶时间以及末尾GPS定位点到下游交叉口的行驶时间三者的加和计算得出;计算公式如下:

$$T_{L2} = t_{2,分离} + t_3 - t_2 + t_{3,分离} \quad (1)$$

其中, $T_{L2}$ 为所调查路段L2的行程时间, $t_{2,分离}$ 为上游交叉口到首个GPS定位点的行驶时间, $t_3 - t_2$ 为此路段上首尾两GPS定位点之间的时间差值, $t_{3,分离}$ 为末尾GPS定位点到下游交叉口的行驶时间;

第二种类型为所调查路段上只存在一个车辆GPS定位点,在这种情况下,所调查路段的行程时间由上游交叉口到此GPS定位点的时间以及此GPS定位点到下游交叉口的行驶时间的加和计算得出:

$$T_{L2} = t_{2,分离} + t_{3,分离} \quad (2)$$

其中, $T_{L2}$ 为所调查路段L2的行程时间, $t_{2,分离}$ 为上游交叉口到GPS定位点的行驶时间, $t_{3,分离}$ 为GPS定位点到下游交叉口的行驶时间;

第三种类型为所调查路段上不存在车辆GPS定位点,在这种情况下,所调查路段的行程时间由此调查路段临近两GPS定位点之间的时间差计算得出:

$$T_{L2} = t_{2,分离} \quad (3)$$

其中, $T_{L2}$ 为所调查路段L2的行程时间, $t_{2,分离}$ 为调查路段临近两GPS定位点之间的时间差的代换值;

步骤二、基于人工神经网络模型构建城市道路路段行程时间估计模型:输入神经元为由车辆GPS获得的位置向量 $p(i)$ 、路段编号向量 $s(i)$ 、时间戳向量 $t(i)$ 、速度向量 $v(i)$ ,对应的输出量为步骤一所述的目标路段的历史行程时间 $T_{s(i)}$ ,通过加载海量GPS数据信息及道路网络信息进行训练,获得训练良好的城市道路路段行程时间计算模型;

利用城市道路路段行程时间估计模型,根据车辆GPS获得的当前时刻的位置向量 $p(i)$ 、路段编号向量 $s(i)$ 、时间戳向量 $t(i)$ 、速度向量 $v(i)$ ,计算得到当前时刻的路段行程时间数据;

步骤三、基于步骤二获得的路段行程时间数据,进一步计算得出路段交通流速度 $V_p$ 和路段交通流密度 $K_p$ ;

步骤四、以路段交通流速度 $V_p$ 和路段交通流密度 $K_p$ 数据为输入条件,判定道路交通拥堵状态。

2. 根据权利要求1所述的一种基于车辆GPS数据的城市道路交通拥堵判别方法,其特征在于:在步骤二中,所述人工神经网络模型的数学描述如下:

输入层

$$X(i) = \begin{bmatrix} x_1(i) \\ \vdots \\ x_N(i) \end{bmatrix} = \begin{bmatrix} p(i) \\ s(i) \\ t(i) \\ v(i) \end{bmatrix} \quad (1)$$

其中 $p(i)$ 是浮动车 $i$ 在上游路段、目标路段和下游路段上的位置向量; $s(i)$ 是路段编号向量,表明浮动车所在路段; $t(i)$ 是时间戳向量,表明浮动车发送信息的时刻; $v(i)$ 是速度向量;

模型中输入神经元的数量由以下决定:

$$N = n * m \quad (2)$$

其中 $n$ 是每辆浮动车所考虑的信息点数量; $m$ 是信息的类别,所述 $m$ 为4分别表示:位置、路段ID、时间戳和速度;

隐藏层

$$H(i) = \begin{bmatrix} h_1(i) \\ \vdots \\ h_m(i) \end{bmatrix} = \begin{bmatrix} \varphi \left( \sum_{j=1}^N \omega_{j,1} x_j(i) + b_1 \right) \\ \vdots \\ \varphi \left( \sum_{j=1}^N \omega_{j,m} x_j(i) + b_m \right) \end{bmatrix} \quad (3)$$

其中 $h_m(i)$ 定义了第 $m$ 个隐藏神经元的值, $\omega_{j,m}$ 定义了连接第 $j$ 个输入神经元和第 $m$ 个隐藏神经元的权重, $b_m$ 定义了有固定值的第 $m$ 个隐藏神经元的偏差; $\varphi$ 是传输函数;传输函数的一般形式是逻辑S型函数和双曲正切函数;

$$\varphi(y) = 1 - \exp(-2y) / (1 + \exp(-2y)) \quad (4)$$

输出层

$$Y(i) = TT(i) = \varphi \left( \sum_{k=1}^m \omega_k h_k(i) + b \right) \quad (5)$$

其中 $Y(i)$ 和 $TT(i)$ 定义了路段上的浮动车 $i$ 的估计行程时间; $\omega_k$ 定义了连接第 $k$ 个隐藏神经元和输出神经元的权重; $b$ 是输出的偏差; $\varphi$ 是传输函数,线性函数用于输出单元。

3. 根据权利要求2所述的一种基于车辆GPS数据的城市道路交通拥堵判别方法,其特征在于:在步骤三中,路段交通流速度 $V_p$ 和路段交通流密度 $K_p$ 的计算过程为:

给定时间帧参数,取值为5分钟、10分钟、15分钟或20分钟;

在第 $p$ 个时间帧 $TF_p$ 范围内,目标路段上交通流速度 $V_p$ 计算公式如下:

$$V_p = L \cdot q / \sum_{i=1}^q TT(i) \quad (9)$$

其中, $L$ 代表路段长度, $q$ 代表此时间帧内途径此路段的车辆数量, $TT(i)$ 代表时间帧 $TF_p$ 范围内第 $i$ 辆车的行程时间;

在时间帧 $TF_p$ 范围内,目标路段上交通流密度 $K_p$ 计算公式如下:

$$K_p = \frac{60 \cdot q}{L \cdot TF_p} \quad (10)。$$

4. 根据权利要求3所述的一种基于车辆GPS数据的城市道路交通拥堵判别方法,其特征  
在于:在步骤四中,判定道路交通拥堵状态的过程为:

给出目标路段的设计时速,根据计算出路段交通流速度 $V_p$ 和路段交通流密度 $K_p$ ,依据道路通行能力手册对城市道路服务水平等级的划分标准,对调查路段的交通拥堵状态判别如下:

在道路设计时速为100km/h的路段中,当 $K_p \leq 10$ 且 $V_p \geq 88$ 时,判定为畅通;当 $10 < K_p \leq 32$ 且 $62 \leq V_p < 88$ 时,判定为缓行;当 $32 < K_p$ 且 $V_p < 62$ 时,判定为拥堵;

在道路设计时速为80km/h的路段中,当 $K_p \leq 10$ 且 $V_p \geq 72$ 时,判定为畅通;当 $10 < K_p < 32$ 且 $55 \leq V_p < 72$ 时,判定为缓行;当 $32 < K_p$ 且 $V_p < 55$ 时,判定为拥堵;

在道路设计时速为60km/h的路段中,当 $K_p \leq 10$ 且 $V_p \geq 55$ 时,判定为畅通;当 $10 < K_p < 32$ 且 $44 \leq V_p < 55$ 时,判定为缓行;当 $32 < K_p$ 且 $V_p < 44$ 时,判定为拥堵。

## 一种基于车辆GPS数据的城市道路交通拥堵判别方法

### 技术领域

[0001] 本发明涉及一种城市道路交通拥堵判别方法。

### 背景技术

[0002] 据公安部数据显示,截止2013年底全国汽车保有量超过1.37亿,相较于2012年增长达到11.4%,全国有31个城市的汽车拥有量超过百万。城市汽车数量的激增,会导致严重的交通拥堵问题,已经成为全国各城市所面临的共同难题,导致巨大的经济损失。据交通部数据显示,交通拥堵每年导致的经济损失达到2500亿元,相当于全年GDP的5%-8%。此外,交通拥堵也会导致城市环境恶化、居民健康水平下降、城市出行满意度降低等间接损失。利用道路交通流量、行驶速度、占有率等数据,对城市道路交通拥堵进行实时判别,一方面能够向公众出行者发布出行信息服务,提高居民的出行满意度;另一方面能够告知城市交通管理部门,以便对交通拥堵进行及时干预及管理,防止交通拥堵的扩散并减低交通拥堵带来的损失,具有重要的现实意义。

[0003] 在以往的研究中,城市道路交通拥堵判别的数据来源广泛,主要包括三类:传统的道路固定交通信息检测器,如线圈检测器、微波检测器、视频检测器等;交叉口自适应控制设备检测器,如Scats、Scoot设备等;专门的道路移动检测器,如浮动车、专用交通信息监测车等。而这些交通信息检测设备,往往存在安装布设的成本高、技术难度大、后期维护运营困难等问题,使得依托于这些检测设备数据的交通拥堵判别方法的应用范围存在较大局限性。通过统计发现,这些研究的实际应用倾向于经济条件好的大城市或城市范围的快速路、主干路等主要路段,也印证了这一问题。

[0004] 随着LBS(Location Based Service)技术的发展普及,城市交通出行的GPS数据(如安装有GPS模块的出租车及公交车、居民的移动通信设备等)成本更低、获取更容易,对城市交通的参与者(行人及车辆)的位置信息的采集变的越来越容易,这些数据成为一种隐性财富被大量的保存下来,而这些海量的位置信息通常以GPS数据的形式存储于各种管理机构及政府部门,利用这些GPS定位点数据进行交通拥堵的判别已经成为近些年来研究的热点。

### 发明内容

[0005] 本发明的目的是提供一种基于车辆GPS数据的城市道路交通拥堵判别方法,以解决现有城市道路交通拥堵判别方法由于采用传统交通信息检测设备,往往存在安装布设的成本高、技术难度大、后期维护运营困难,使得依托于这些检测设备数据的交通拥堵判别方法的应用范围存在较大局限性的问题。

[0006] 本发明为解决上述技术问题采取的技术方案是:

[0007] 一种基于车辆GPS数据的城市道路交通拥堵判别方法,所述方法的实现过程为:

[0008] 步骤一、以行驶于城市道路的车辆GPS数据为基础,结合城市道路拓扑结构信息,对不同类型的城市道路路段行程时间分配进行划分;得到目标路段的历史行程时间 $T_{s(i)}$ ;

[0009] 步骤二、基于人工神经网络模型构建城市道路路段行程时间估计模型：输入神经元为由车辆GPS获得的位置向量 $p(i)$ 、路段编号向量 $s(i)$ 、时间戳向量 $t(i)$ 、速度向量 $v(i)$ ，对应的输出量为步骤一所述的目标路段的历史行程时间 $T_{s(i)}$ ，通过加载海量GPS数据信息及道路网络信息进行训练，获得训练良好的城市道路路段行程时间计算模型；

[0010] 利用城市道路路段行程时间估计模型，根据车辆GPS获得的当前时刻的位置向量 $p(i)$ 、路段编号向量 $s(i)$ 、时间戳向量 $t(i)$ 、速度向量 $v(i)$ ，计算得到当前时刻的路段行程时间数据；

[0011] 步骤三、基于步骤二获得的路段行程时间数据，进一步计算得出路段交通流速度 $V_p$ 和路段交通流密度 $K_p$ ；

[0012] 步骤四、以路段交通流速度 $V_p$ 和路段交通流密度 $K_p$ 数据为输入条件，判定道路交通拥堵状态。

[0013] 在步骤一中，所述目标路段的历史行程时间的到得方式为：

[0014] 由于车辆GPS数据计算出的行程时间是车辆自一个路段的某一位置行驶到另一路段的某一位置得到的；将这一过程可以分为三种类型，并分别给出计算行程时间的方法：

[0015] 第一种类型为所调查路段上存在至少两个车辆GPS定位点，在这种情况下，所调查路段的行程时间由此路段上首尾两GPS定位点之间的时间差值、上游交叉口到首个GPS定位点的行驶时间以及末尾GPS定位点到下游交叉口的行驶时间三者的加和计算得出；计算公式如下：

$$[0016] \quad T_{L2} = t_{2, \text{分离}} + t_3 - t_2 + t_{3, \text{分离}} \quad (1)$$

[0017] 其中， $T_{L2}$ 为所调查路段 $L2$ 的行程时间， $t_{2, \text{分离}}$ 为上游交叉口到首个GPS定位点的行驶时间， $t_3 - t_2$ 为此路段上首尾两GPS定位点之间的时间差值， $t_{3, \text{分离}}$ 为末尾GPS定位点到下游交叉口的行驶时间；

[0018] 第二种类型为所调查路段上只存在一个车辆GPS定位点，在这种情况下，所调查路段的行程时间由上游交叉口到此GPS定位点的时间以及此GPS定位点到下游交叉口的行驶时间的加和计算得出：

$$[0019] \quad T_{L2} = t_{2, \text{分离}} + t_{3, \text{分离}} \quad (2)$$

[0020] 其中， $T_{L2}$ 为所调查路段 $L2$ 的行程时间， $t_{2, \text{分离}}$ 为上游交叉口到GPS定位点的行驶时间， $t_{3, \text{分离}}$ 为GPS定位点到下游交叉口的行驶时间；

[0021] 第三种类型为所调查路段上不存在车辆GPS定位点，在这种情况下，所调查路段的行程时间由此调查路段临近两GPS定位点之间的时间差计算得出：

$$[0022] \quad T_{L2} = t_{2, \text{分离}} \quad (3)$$

[0023] 其中， $T_{L2}$ 为所调查路段 $L2$ 的行程时间， $t_{2, \text{分离}}$ 为调查路段临近两GPS定位点之间的时间差的代换值。

[0024] 在步骤二中，所述人工神经网络模型(ANN模型)的数学描述如下：

[0025] 输入层

$$[0026] \quad X(i) = \begin{bmatrix} x_1(i) \\ \vdots \\ x_N(i) \end{bmatrix} = \begin{bmatrix} p(i) \\ s(i) \\ t(i) \\ v(i) \end{bmatrix} \quad (1)$$

[0027] 其中 $p(i)$ 是浮动车 $i$ 在上游路段、目标路段和下游路段上的位置向量; $s(i)$ 是路段编号向量,表明浮动车所在路段; $t(i)$ 是时间戳向量,表明浮动车发送信息的时刻; $v(i)$ 是速度向量;

[0028] 模型中输入神经元的数量可以由以下决定:

$$[0029] \quad N = n * m \quad (2)$$

[0030] 其中 $n$ 是每辆浮动车所考虑的信息点数量; $m$ 是信息的类别,所述 $m$ 为4分别表示:位置、路段ID、时间戳和速度;

[0031] 隐藏层

$$[0032] \quad H(i) = \begin{bmatrix} h_1(i) \\ \vdots \\ h_m(i) \end{bmatrix} = \begin{bmatrix} \varphi \left( \sum_{j=1}^N \omega_{j,1} x_j(i) + b_1 \right) \\ \vdots \\ \varphi \left( \sum_{j=1}^N \omega_{j,m} x_j(i) + b_m \right) \end{bmatrix} \quad (3)$$

[0033] 其中 $h_m(i)$ 定义了第 $m$ 个隐藏神经元的值, $\omega_{j,m}$ 定义了连接第 $j$ 个输入神经元和第 $m$ 个隐藏神经元的权重, $b_m$ 定义了有固定值的第 $m$ 个隐藏神经元的偏差; $\varphi$ 是传输函数;传输函数的一般形式是逻辑S型函数和双曲正切函数;

$$[0034] \quad \varphi(y) = 1 - \exp(-2y) / (1 + \exp(-2y)) \quad (4)$$

[0035] 输出层

$$[0036] \quad Y(i) = TT(i) = \varphi \left( \sum_{k=1}^m \omega_k h_k(i) + b \right) \quad (5)$$

[0037] 其中 $Y(i)$ 和 $TT(i)$ 定义了路段上的浮动车 $i$ 的估计行程时间; $\omega_k$ 定义了连接第 $k$ 个隐藏神经元和输出神经元的权重; $b$ 是输出的偏差; $\varphi$ 是传输函数,线性函数通常用于输出单元。

[0038] 在步骤三中,路段交通流速度 $V_p$ 和路段交通流密度 $K_p$ 的计算过程为:

[0039] 给定时间帧参数,取值为5分钟、10分钟、15分钟或20分钟;

[0040] 在第 $p$ 个时间帧 $TF_p$ 范围内,目标路段上交通流速度 $V_p$ 计算公式如下:

$$[0041] \quad V_p = L \cdot q / \sum_{i=1}^q TT(i) \quad (9)$$

[0042] 其中, $L$ 代表路段长度, $q$ 代表此时间帧内途径此路段的车辆数量, $TT(i)$ 代表时间帧 $TF_p$ 范围内第 $i$ 辆车的行程时间;

[0043] 在时间帧 $TF_p$ 范围内,目标路段上交通流密度 $K_p$ 计算公式如下:

$$[0044] \quad K_p = \frac{60 \cdot q}{L \cdot TF_p} \quad (10)$$

[0045] 在步骤四中,判定道路交通拥堵状态的过程为:

[0046] 给出目标路段的设计时速,根据计算出路段交通流速度 $V_p$ 和路段交通流密度 $K_p$ ,依据道路通行能力手册(HCM 2000)对城市道路服务水平等级的划分标准,对调查路段的交通拥堵状态判别如下:

[0047] 在道路设计时速为100km/h的路段中,当 $K_p \leq 10$ 且 $V_p \geq 88$ 时,判定为畅通;当 $10 < K_p \leq 32$ 且 $62 \leq V_p < 88$ 时,判定为缓行;当 $32 < K_p$ 且 $V_p < 62$ 时,判定为拥堵;

[0048] 在道路设计时速为80km/h的路段中,当 $K_p \leq 10$ 且 $V_p \geq 72$ 时,判定为畅通;当 $10 < K_p < 32$ 且 $55 \leq V_p < 72$ 时,判定为缓行;当 $32 < K_p$ 且 $V_p < 55$ 时,判定为拥堵;

[0049] 在道路设计时速为60km/h的路段中,当 $K_p \leq 10$ 且 $V_p \geq 55$ 时,判定为畅通;当 $10 < K_p < 32$ 且 $44 \leq V_p < 55$ 时,判定为缓行;当 $32 < K_p$ 且 $V_p < 44$ 时,判定为拥堵。

[0050] 本发明的有益效果是:

[0051] 本发明方法是对城市交通拥堵进行实时判别,而不是对下一时刻的拥堵进行预测,重点在于“实时”,能实时预测城市交通拥堵状态,即提供当前时刻的GPS数据便能迅速准确地判别交通拥堵状态。

[0052] 本发明提供的基于车辆GPS数据的城市道路交通拥堵判别方法,以城市道路中采集的车辆GPS数据为基础,结合GPS定位点在道路中不同的路段行程时间分配类型信息,构建人工神经网络模型,计算路段行程时间,进而能够获得道路路段交通流速度及交通流密度信息,最终进行道路交通拥堵状态判别。该方法适用于能够采集GPS数据的任意城市道路路段,具有较强的普适性。

## 附图说明

[0053] 图1是本发明所述城市道路交通拥堵判别方法的原理示意图;图2是本发明方法的流程框图;图3为路段行程时间分配示意图,其中:(a)为类型1的行程时间分配示意图,(b)为类型2的行程时间分配示意图,(c)为类型3的行程时间分配示意图;图4为路段行程时间估计的人工神经网络结构示意图;图5为路段交通拥堵判别流程图。

## 具体实施方式

[0054] 具体实施方式一:结合图1~5,本实施方式针对所述基于车辆GPS数据的城市道路交通拥堵判别方法进行详细阐述,

[0055] (1)、所述基于车辆GPS数据的城市道路交通拥堵判别方法的功能是进行城市道路交通拥堵状态判别,所述判别方法包括四个步骤:1)以行驶于城市道路的车辆GPS数据为基础,结合城市道路拓扑结构信息,对不同类型的城市道路路段行程时间进行分配;2)构建人工神经网络模型,输入神经元为车辆位置点、时间戳、车辆速度等信息,加载海量GPS数据信息及道路网络信息进行训练,获得训练良好的城市道路路段行程时间计算模型;3)基于获得的路段行程时间数据,进一步计算得出路段交通流密度及速度数据;4)以路段交通流密度及速度数据为输入条件,判定道路交通拥堵状态。其原理(系统架构)如图1所示。

[0056] (2)城市道路路段行程时间分配



[0057] 由于车辆GPS数据计算出的行程时间并不是源自独立的完整路段,而是车辆自一个路段的某一位置行驶到另一路段的某一位置得到的。这一过程可以分为3种类型,如图3所示。

[0058] 本发明将城市道路路段行程时间分配划分为三种类型,是通过统计历史海量的GPS数据,发现这三种类型的比例更高,达到95%以上,而其他类型占比较少,如果也考虑进来会降低道路交通拥堵判别的效率。而划分类型越细,准确率越高,统一的方法的话会降低准确率,因此给出三种分配类型,结合所调查路段的实际情况,选择某一具体类型来计算路段行程时间。如图3所示。

[0059]  $P_0, P_1, P_2, P_3, P_4$ 位于相关路段上,  $t_0, t_1, t_2, t_3, t_4$ 是时间戳。 $t'_1, t'_2, t'_3, t'_4$ 表示基于浮动车GPS采集到的行程时间进行重新分配得到的路段行程时间。完整的路段行程时间定义为:当车辆通过上游停车线的时间点与车辆通过下游停车线的时间点之间的时间差。

[0060] 类型1:如图3(a)所示,记录的位置在相同的路段上,路段2的完整行程时间由三部分组成:

$$[0061] \quad T_{L2} = t_{2, \text{分离}} + t_3 - t_2 + t_{3, \text{分离}} \quad (6)$$

[0062] 对于这种情况,由于路段空间长度较大或目标路段上的交通状况比较拥挤,或是车辆需要等待红灯,浮动车在这个路段上的行程时间相对较长。

[0063] 类型2:如图3(b)所示,第一个和第二个记录的位置在邻近的路段上,路段2的行程时间估计如下:

$$[0064] \quad T_{L2} = t_{2, \text{分离}} + t_{3, \text{分离}} \quad (7)$$

[0065] 类型3:如图3(c)所示,两个连续记录的位置之间至少有一个完整路段存在,路段2的行程时间是:

$$[0066] \quad T_{L2} = t_{2, \text{分离}} \quad (8)$$

[0067] 在这种情况下,由于目标路段可能处于自由流或非饱和状态,浮动车在路段上的行驶时间较短。因此下一步需要的问题是如何仅基于浮动车GPS数据重新分配行程时间到单个路段上。这里采用人工神经网络模型和一个解析模型。

[0068] (3)基于人工神经网络的路段行程时间估计

[0069] 基本上,浮动车GPS采集到的交通数据包括路径上的位置、时间戳和速度,其可以用于人工神经网络模型(ANN)的输入数据。由于交通流和信号配时在城市路网上并不是一直有效的,因此我们试图开发一个模型来尽可能利用最少的信息准确地估计行程时间,同时增强模型的普适性。在我们的ANN模型中,假设浮动车在当前样本时段经历的交通状况与相同车辆在之前的样本时段遍历的路径相似,之前的样本时段内浮动车GPS信息结合了当前的样本时段内的信息。相关ANN模型结构如图4所示。

[0070] ANN模型的数学描述如下:

[0071] ①输入层

$$[0072] \quad X(i) = \begin{bmatrix} x_1(i) \\ \vdots \\ x_N(i) \end{bmatrix} = \begin{bmatrix} p(i) \\ s(i) \\ t(i) \\ v(i) \end{bmatrix} \quad (9)$$

[0073] 其中 $p(i)$ 是浮动车 $i$ 在上游路段、目标路段和下游路段上的位置向量 $s(i)$ 是路段编号向量,表明浮动车所在路段,例如上述公式中所述 $TL_2$ 中下标 $L_2$ ;  $t(i)$ 是时间戳向量,表明浮动车发送信息的时刻;  $v(i)$ 是速度向量。

[0074] 模型中输入神经元的数量可以由以下决定:

[0075]  $N=n*m$  (10)

[0076] 其中 $n$ 是每辆浮动车所考虑的信息点数量;  $m$ 是信息的类别,这里 $m$ 为4(位置、路段ID、时间戳和速度)。

[0077] 对图3(a)的情形,需要考虑之前时段内的信息,因此对于每辆浮动车输入神经元是 $5 \times 4$ (5个位置+5个路段ID+5个时间戳+5个速度)。对于图3(b)的情形,使用了 $4 \times 4$ 个神经元,而对于图3(c)的情形需要 $3 \times 4$ 个神经元。

[0078] ②隐藏层

$$[0079] \quad H(i) = \begin{bmatrix} h_1(i) \\ \vdots \\ h_m(i) \end{bmatrix} = \begin{bmatrix} \varphi \left( \sum_{j=1}^N \omega_{j,1} x_j(i) + b_1 \right) \\ \vdots \\ \varphi \left( \sum_{j=1}^N \omega_{j,m} x_j(i) + b_m \right) \end{bmatrix} \quad (11)$$

[0080] 其中 $h_m(i)$ 定义了第 $m$ 个隐藏神经元的值,  $\omega_{j,m}$ 定义了连接第 $j$ 个输入神经元和第 $m$ 个隐藏神经元的权重,  $b_m$ 定义了有固定值的第 $m$ 个隐藏神经元的偏差;  $\varphi$ 是传输函数。传输函数的一般形式是逻辑S型函数和双曲正切函数。而在实际运用中,双曲正切函数的收敛速度更快。因此,我们选择:

$$[0081] \quad \varphi(y) = 1 - \exp(-2y) / (1 + \exp(-2y)) \quad (12)$$

[0082] ③输出层

$$[0083] \quad Y(i) = TT(i) = \varphi \left( \sum_{k=1}^m \omega_k h_k(i) + b \right) \quad (13)$$

[0084] 其中 $Y(i)$ 和 $TT(i)$ 定义了路段上的浮动车 $i$ 的估计行程时间;  $\omega_k$ 定义了连接第 $k$ 个隐藏神经元和输出神经元的权重;  $b$ 是输出的偏差;  $\varphi$ 是传输函数,线性函数通常用于输出单元。

[0085] 利用海量的历史车辆GPS数据对此神经网络模型的训练,而此历史数据量越大越好,而以特定的时间周期(如:周、月、年)内的数据作为成套输入数据为佳,这样能够将城市道路交通流变化的周期性考虑进来。经过训练,此神经网络模型达到均衡最优,即为基于人工神经网络的路段行程时间估计模型。

[0086] 通过将实时采集而来的浮动车经纬度坐标、瞬时速度、时间戳等信息录入此训练完备的模型中,能够得到实时道路行程时间。

[0087] (4)路段交通流速度及密度计算

[0088] 给定时间帧参数 $TF$ ,以便统计特定时间范围内的所有车辆的路段行程时间,而时间帧的范围大小由道路等级、道路路段长度、智能交通应用的实际要求等因素决定。时间帧范围过小,会导致此范围内车辆GPS定位数量过少,精确度差;时间帧范围过大,无法真实反

映城市道路网络内交通流的“瞬息万变”。本发明建议的时间帧范围包括：5分钟、10分钟、15分钟、20分钟四种尺度，其中以5分钟为最佳。

[0089] 在时间帧 $TF_p$ 范围内，此路段上交通流速度 $V_p$ 计算公式如下：

$$[0090] \quad V_p = L \cdot q / \sum_{i=1}^q TT(i) \quad (9)$$

[0091] 其中， $L$ 代表路段长度， $q$ 代表此时间帧内途径此路段的车辆数量， $TT(i)$ 代表时间帧 $TF_p$ 范围内第 $i$ 辆车的行程时间。

[0092] 在时间帧 $TF_p$ 范围内，此路段上交通流密度 $K_p$ 计算公式如下： $K_p = \frac{60 \cdot q}{L \cdot TF_p}$  (10)

[0093] (5)路段交通拥堵判别

[0094] 本发明采用如图5的判断逻辑，判别道路路段交通拥堵状态。输入条件为路段交通流密度 $k$ 及路段交通流速度 $v$ 。图5中，路段交通流密度 $k$ 及路段交通流速度 $v$ 的单位分别为pcu/km/h及km/h。虚线箭头代表判断畅通，细线箭头代表判断缓行，粗线箭头代表判断拥堵。

[0095] 以上所述，仅为本发明较佳的具体实施方式，但本发明的保护范围并不局限于此，任何熟悉本技术领域的技术人员在本发明揭露的技术范围内，根据本发明的技术方案及其发明构思加以等同替换或改变，都应涵盖在本发明的保护范围之内。




图1

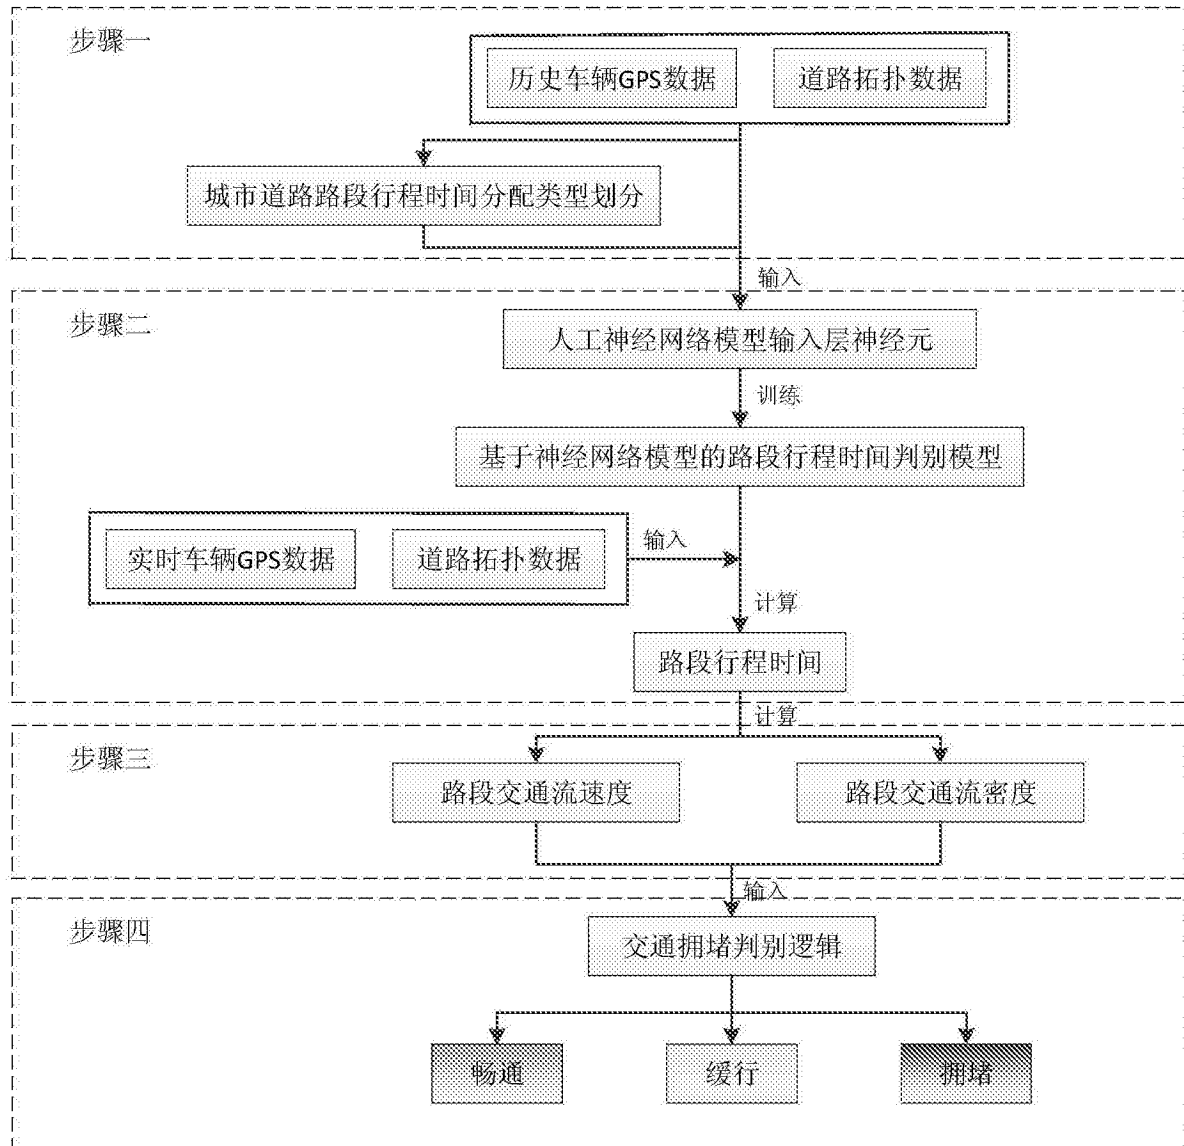


图2


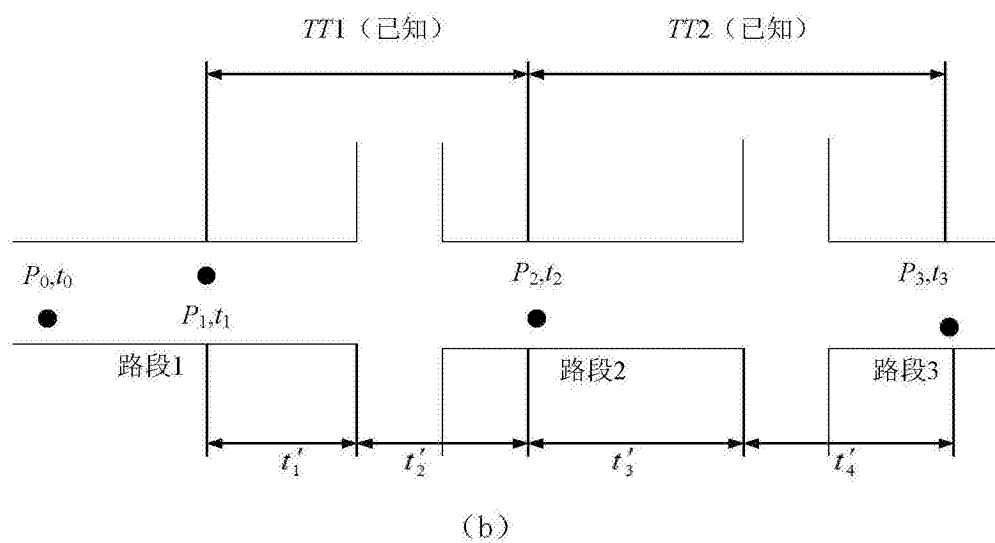
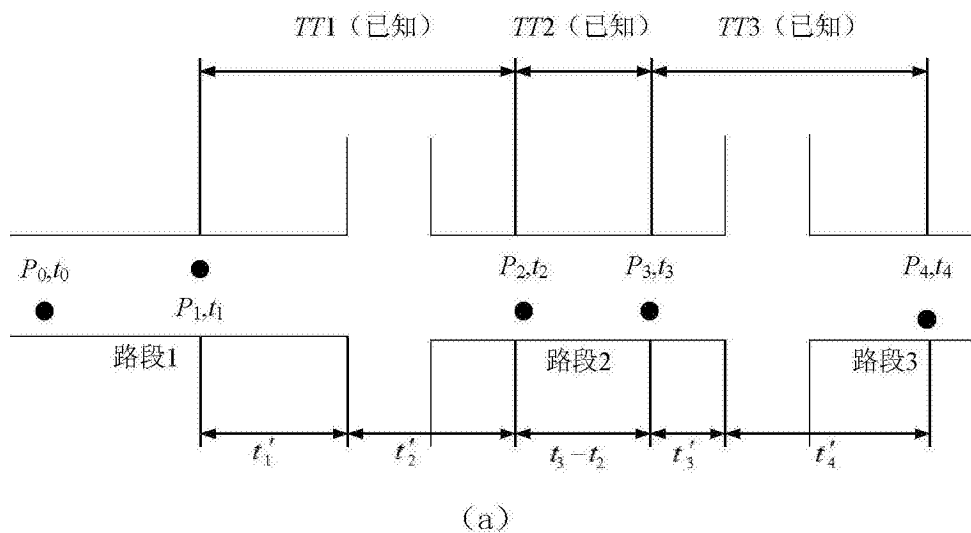


图3




图4

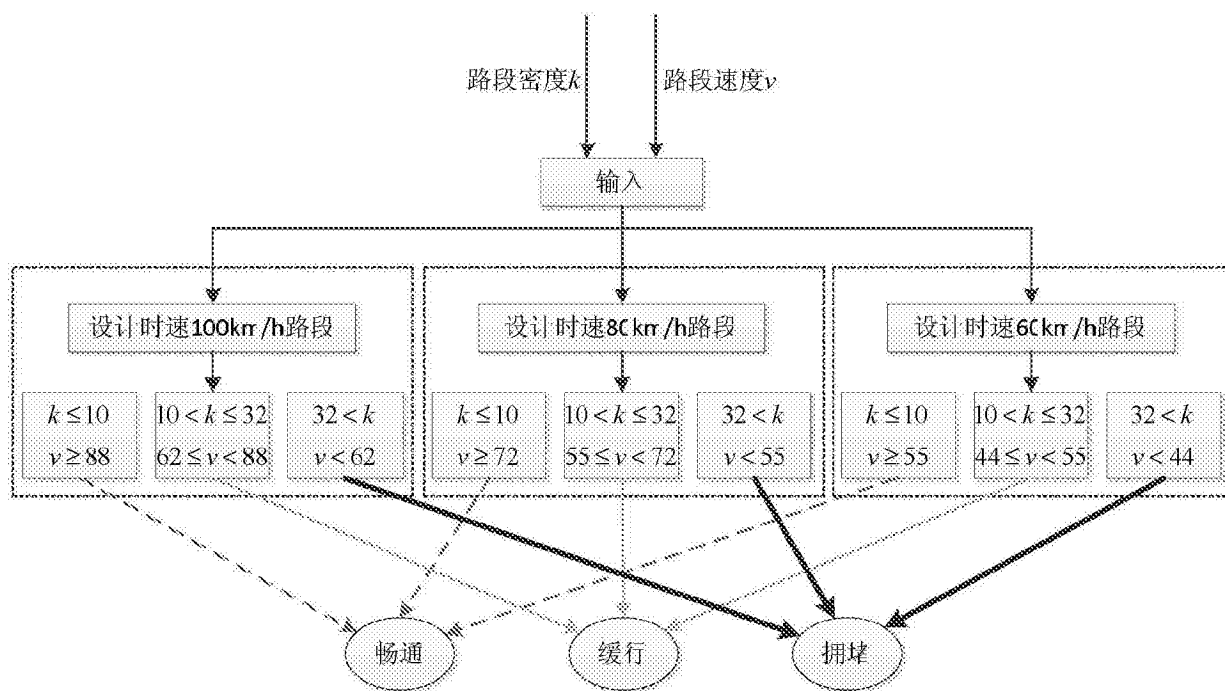


图5